

MATHEUS VINICIUS INAGAKI MORAES

Mogi das Cruzes, São Paulo, Brasil | +55 11 99147-3511 | matheusinagakimoraes97@gmail.com | LinkedIn: linkedin.com/in/mvinagaki | GitHub: github.com/mtsvi-moraes

RESUMO PROFISSIONAL

AI Engineer com 5 anos de experiência no desenvolvimento de soluções de Machine Learning e Inteligência Artificial, com foco na arquitetura de IA Generativa, RAG e Agentes Autônomos em Python. Especialista em reduzir custos operacionais e garantir a privacidade de dados através do fine-tuning e inferência local de LLMs open-source. Com vivência internacional no Japão, inglês fluente e reconhecimento como finalista regional na América Latina em desafios globais da NASA e IBM, atuo na tradução de regras de negócios complexas em infraestrutura Cloud escalável (Microsoft Azure) e soluções de alto impacto.

COMPETÊNCIAS TÉCNICAS

- Linguagens e Frameworks:** Python, PyTorch, Scikit-Learn, LangChain, FastAPI, Flask, OpenCV.
- IA Generativa & Machine Learning:** LLMs Open-Source, RAG, Fine-Tuning, Agentes Autônomos (Gemini, Claude, Llama), Bancos Vetoriais (ChromaDB, Pinecone), Visão Computacional.
- Cloud, Dados e Infraestrutura:** Microsoft Azure, Docker, Linux, Apache Spark, Delta Live Tables, SQL Server, Data Lakes, Data Warehouses.
- Engenharia de Software:** Arquitetura de APIs RESTful, OpenAPI/Swagger, OOP, Clean Code, MLOps.

EXPERIÊNCIA PROFISSIONAL

Pesquisador de IA Open-Source

AI Engineer Freelance e Pesquisa Aplicada em IA Generativa Junho 2025 - Atual

- Orquestração de Agentes:** Realizei experimentos de fine-tuning com LLMs open-source em bases clínicas públicas, comparando desempenho contra modelos proprietários como baseline e reduzindo custos de inferência em fluxos automatizados com n8n.
- Fine-Tuning para o Setor da Saúde:** Arquiteteei e disponibilizei repositórios públicos contendo pipelines complexos de múltiplos agentes em Python, integrando os modelos Gemini, Claude e Llama para a geração automatizada de guias de estudo técnico.
- Deploy e Engenharia de RAG:** Apliquei princípios de Clean Code e OOP para transformar scripts experimentais em código escalável, realizando o deploy da aplicação final diretamente na infraestrutura do Hugging Face.

Grupo Stefanini

AI Research Scientist Maio 2023 - Junho 2025 | Brasil

Promoção interna após atuação como Data Scientist II em operações North America & APAC.

Foco em IA Generativa, RAG, LLMs open-source, NLP, APIs RESTful e deploy em Azure

- RAG Jurídico (TJRS):** Reduzi o tempo de processamento de documentos em 40% desenvolvendo sistemas RAG em colaboração com especialistas (SMEs) para mapear jargões legais complexos.
- LLMs Corporativos:** Eliminei custos com APIs proprietárias e reduzi a exposição de dados sensíveis ao substituir APIs proprietárias por pipelines de inferência local com modelos open-source em ambiente privado.
- Workflows Multiagentes & Cloud:** Orquestrei fluxos avançados com LangChain (Python) e realizei o deploy de aplicações de NLP/Visão Computacional via Docker, publicando APIs RESTful no Azure.

Grupo Stefanini

Data Scientist II

Setembro 2021 - Julho 2023 | North America & APAC

- **Pipelines de Big Data e ML:** Automatizei a classificação de tickets de suporte desenvolvendo um modelo SVM próprio com 92% de acurácia sobre um histórico de mais de 20 milhões de tickets legados. Eliminei a dependência de triagem manual ao integrar a inferência a pipelines distribuídos (Apache Spark, Delta Live Tables), processando chamados em larga escala e alimentando dashboards de BI com dados confiáveis.
- **Infraestrutura para Visão Computacional:** Garanti alta performance e baixa latência administrando servidores Linux (Ubuntu) para algoritmos de detecção de ponta a ponta (OpenCV).
- **Coleta e Ingestão de Dados:** Desenvolvi web scrapers e pipelines de NLP em Python, automatizando a ingestão direta em bancos SQL Server e Data Lakes.

Instituto Butantan

Data Scientist (Consultoria/Freelance)

Abril 2021 - Janeiro 2022

- **Modelagem Clínica Preditiva:** Desenvolvi modelos de classificação (XGBoost, Random Forest e Redes Neurais) para prever riscos de infecção por SARS-CoV-2, alcançando métricas de alta performance (ROC/AUC) e estratificando pacientes com precisão.
- **Tradução Técnica para Negócios:** Atuei como ponte entre dados e saúde, traduzindo métricas estatísticas complexas em relatórios acionáveis que guiaram a tomada de decisão do corpo clínico.
- **Rigor Estatístico em Dados Sensíveis:** Processei bases clínicas de alta complexidade aplicando técnicas para evitar vieses preditivos, como balanceamento de classes (SMOTE), redução de dimensionalidade (PCA) e cross-validation.

EDUCAÇÃO

Universidade Anhembi Morumbi

Bacharelado em Ciência da Computação

Previsão: Agosto 2027

Universidade Anhanguera Educacional

CST em Ciência de Dados

Janeiro 2021 - Interrompido

PRÊMIOS E CERTIFICAÇÕES

- **Finalista Regional (América Latina):** NASA Space Apps Challenge & IBM Call for Code. Atuei na liderança de engenharia de IA para o Projeto SpecWater em 2021.

IDIOMAS

- **Inglês:** Fluente. Experiência em times globais e atuação como professor de inglês durante residência no Japão.
- **Japonês:** Intermediário Superior (Proficiência Profissional). Fluência prática desenvolvida por meio de imersão cultural e vivência diária no país.
- **Português:** Nativo.